

Diyabetik Retinopati Hastalığının Erken Tespiti İçin Derin Öğrenme İle Retina Görüntülerinin Sınıflandırılması

Classification of Retinal Images with Deep Learning for Early Detection of Diabetic Retinopathy Disease

Yrd.Doç.Dr. Nursel YALÇIN
Gazi Üniversitesi Gazi Eğitim Fakültesi
Bilgisayar ve Öğretim Teknolojileri Eğitimi Bölümü
Ankara, Türkiye
nyalcin@gazi.edu.tr

Seyfullah ALVER
Milli Savunma Üniversitesi Kara Harp Okulu
Bilgisayar Mühendisliği Bölümü
Ankara, Türkiye
salver@kho.edu.tr

Necla ULUHATUN
GenelKurmaya Başkanlığı
Bilg.Sis.D.Bşk.
Ankara, Türkiye
neclauluhatur@gmail.com

Özetçe— Diyabetik retinopati diyabete (şeker hastalığı) bağlı olarak gözde meydana gelen en yaygın körlük nedenidir. Bu sebeple diyabetik retinopatinin erken tespit edilerek tedaviye erken başlanması görme yetisinin kaybedilmemesi açısından önem arz etmektedir. Bu çalışmada retina görüntülerinden diyabetik retinopati hastalığının erken tespiti için derin öğrenme tabanlı bir yaklaşım sunulmuştur. Önerilen yaklaşım temel olarak iki aşamadan oluşmaktadır. İlk aşamada farklı veri setlerinden elde edilen retina görüntülerini gürültüden arındırmak ve boyut olarak standart hale getirmek amacıyla ön işlem uygulanmış ikinci aşamada derin öğrenme algoritması olan Konvolüsyonel Sinir Ağları yöntemiyle sınıflandırma yapılmış ve %98,5 başarı elde edilmiştir. Bu çalışmanın benzer çalışmalardan en belirgin farkı öznelite kümesinin geleneksel yöntemlerdeki gibi manuel hesaplanarak oluşturulması yerine derin öğrenme ağının eğitim aşamasında CPU ve GPU kullanarak, çok kısa sürede kendi kendine öğrenerek otomatik olarak oluşturmasıdır.

Anahtar Kelimeler — derin öğrenme; diyabetik retinopati; konvolüsyonel sinir ağı.

Abstract— Diabetic retinopathy is the most common cause of blindness of the eye depend on diabetes. For this reason, early detection of diabetic retinopathy is of critical importance. In this study, a deep learning-based approach is presented for the early detection of diabetic retinopathy from retinal images. The proposed approach consists of two steps. In the first stage, pretreatments were performed to remove retinal images from different data sets and standardize them to size. In the second stage, classification was made by Convolutional Neural Network which is a deep learning algorithm and 98.5% success was achieved. The most prominent difference of this study from similar studies is that instead of creating the feature set manually as in traditional methods, the deep learning network


automatically constructs itself in a very short time by using the CPU and GPU in training phase.

Keywords — deep learning; diabetic retinopathy; convolutional neural network;

I. GİRİŞ

Diyabete bağlı retina bozukluklarına Diyabetik Retinopati (DR) denilmektedir. DR, en yaygın körlük sebeplerinden biridir. Bu yüzden DR'nin erken tespiti görme yeteneğinin kaybedilmemesi için ciddi önem arz etmektedir. Yapılan araştırmaya göre [1] 2013 yılında dünyadaki diyabetli hasta sayısı 382 milyon iken bu sayının 2035 yılında 592 milyona çıkacağı öngörülmektedir. DR hastalığı erken teşhis edilirse görme kaybı engellenebilmektedir. Bu nedenle diyabet hastalarının uzman bir göz hekimi tarafından her yıl taramadan geçmeleri elzem bir durum olmaktadır. Fakat bu işlem zaman almakta ve dünyadaki göz hekimi sayısı da diyabetli hasta sayısına oranla yetersiz kalmaktadır. Bu amaçla hekimlere yardımcı olan otomatik karar destek, uzman vb. sistemlerden faydalanmak kaçınılmaz hale gelmiştir [2]. DR hastalığı iki kategoride incelenebilir: Non-Proliferatif Diyabetik Retinopati (NPDR) ve Proliferatif Diyabetik Retinopati (PDR). NPDR hastalığın erken aşaması; PDR ise ilerlemiş aşamasıdır. NPDR, hafif, orta ve şiddetli olarak 3 aşamada incelenir. Hafif aşamada retina görüntülerinde izlenen bulgular mikroanevrizmalar (MAs), orta aşamada eksüdalar (EXs), şiddetli aşamada ise kanamalar (HMs) [3]. Şekil 1'de örnek retina görüntüleri ve aşamaları belirtilmiştir.

DR hastalığının erken tespiti için literatürde birçok çalışma mevcuttur. [4][5][6] ve [7]'deki çalışmalarda öznelite çıkarımına dayalı yöntemler kullanılarak retina görüntüleri



Şekil. 1. Retina görüntüsü ve DR aşamaları: (a) normal retina, (b) hafif NPDR, (c) orta NPDR, (d) şiddetli NPDR.

sınıflandırılmıştır. Öznitelik çıkarımına dayalı yöntemlerde öznitelikler elde edilirken her veri setine ait ayırt edici öznitelikler kullanılmakta bu sebeple öznitelik kümesi veri setine özgü olmaktadır. Dolayısıyla bir veri seti için sınıflandırma başarısı yüksek çıkarken aynı yöntem farklı bir veri seti için kullanıldığında sınıflandırma başarısı çok düşük çıkmakta bu da ciddi sorun teşkil etmektedir. Ayrıca öznitelik çıkarım aşaması da sınıflandırma yapmadan önce ciddi bir hesaplama maliyeti oluşturmaktadır. Bu çalışmada DR hastalığının erken tespiti için, sağlıklı retina görüntüleri ve hastalık derecesine bakılmaksızın hastalıklı retina görüntülerini sınıflandırmak için derin öğrenme tabanlı bir yöntem önerilmiştir. Önerilen yöntemin akış şeması Şekil 2’de gösterilmiştir. Önerilen yaklaşım temel olarak iki adımdan oluşmaktadır. İlk aşama önileşim aşaması, ikinci aşama derin öğrenme ile sınıflandırma aşamasıdır.

II. MATERYAL VE METOT


A. Retina Veri Seti

Bu çalışmada, farklı renk, parlaklık, boyut ve kalitede olmak üzere toplam 1000 retina görüntüsü kullanılmıştır. Bu görüntüler genel erişime açık MESSIDOR, DIARETDB, STARE veri tabanlarından elde edilmiştir. Bu görüntülerden 500’ü normal retina görüntüsü 500’ü hastalıklı retina görüntüleridir.

B. Derin Öğrenme

Derin Öğrenme, Yapay Sinir Ağları (YSA) yönteminin bir alt dalı olarak düşünülebilir. Derin Öğrenme metodunun klasik YSA modellerinden en belirgin farklarından birisi çok sayıda katman ile çalışabilmesidir. Geleneksel YSA’daki her düğüm (node) bir önceki ve bir sonraki katmanlardaki tüm düğümlere bağlıdır. Her bağlantı için hesaplanması gereken matematiksel işlemler bulunmaktadır [8]. Katman sayısının ve düğüm sayısının ciddi oranda artması yüksek miktarda CPU gücü gerektirmektedir.

Derin bir ağ yapısı oluşturmak için kişisel bilgisayarlar içerisindeki CPU tam manasıyla yeterli olmamakta bu da



Şekil. 2. Önerilen yöntemin akış şeması.

problemlerin derin öğrenme ile çözülebilmesinde ciddi sorun oluşturmaktadır. Bu noktada GPU (Grafik işlem birimi) olarak bilinen kavram ortaya çıkmıştır. GPU ile hızlandırılmış işlemci, grafik işleme biriminin (GPU) bir CPU ile birlikte kullanılarak derin öğrenme, analiz ve mühendislik uygulamalarının hızlandırılmasıdır. GPU sayesinde oldukça karmaşık problemler çok kısa sürede derin öğrenme yöntemiyle çözülebilmektedir. Kullanıcıya yansıyan yanı ise uygulamaların çok daha hızlı çalışmasıdır. Derin öğrenme yöntemini diğer yöntemlerden ayıran en belirgin özelliklerden biri de, ağa verilen çok sayıda girdiden en önemli ve sınıflandırma sonucuna önemli ölçüde etki edecek olan öznitelikleri öğrenerek kendisinin tespit etmesidir. Fakat bu ayırt edici girdilerin başarıyla tespit edilebilmesi için derin öğrenme modelinin yeterince fazla sayıda örnek ve farklı durum ile eğitilmesi şarttır. Ayırt edici özniteliklerin öğrenilmesi oluşturulan ağ modelinin katmanlarına bağlıdır. Alt katmanlar daha az ayırt ediciyken üst katmanlar daha çok ayırt edici özniteliklere sahiptir.

Geleneksel makine öğrenmesi metodlarında öğrenme işlemi gerçekleştirilirken öznitelik kümesinin manuel olarak oluşturulması gerekir. Böyle durumlarda öznitelik kümesi hem veri setine hem de kümeyi oluşturan canlıya bağımlı olmaktadır. Derin öğrenmede ise öznitelik kümesi ağır eğitim aşamasında kendi kendine öğrenilerek oluşturulur. Bu sebepten dolayı derin öğrenme yönteminin başarısı klasik algoritmalarla oranla bir hayli fazladır [9].

III. DENEYSEL ÇALIŞMA

Bu çalışmada retina görüntülerini normal ve hasta (DR) olarak sınıflandırmak için derin öğrenmeye dayalı bir yöntem önerilmiştir. Bu sebeple ilk olarak retina görüntüleri ön işlem aşamasından geçirilmiş daha sonra elde edilen görüntüler eğitim verisi (%80) ve test verisi (%20) olarak ayrılmıştır. Oluşturulan derin ağ modeli eğitim verisi ile eğitilerek modelin kendi kendine öğrenmesi ve retina görüntüleri için ayırt edici özelliklerin belirlenmesi sağlanmıştır. Daha sonra test verisi ile önerilen yöntem test edilmiştir.

A. Ön işlem


Retina görüntüleri elde edilirken kayıt ortamı, cihazı vb. sebeplerden ötürü görüntüler, farklı renk, parlaklık ve kalitede olurken aynı zamanda gürültüler de oluşmaktadır. Bu adımın amacı bu gürültüleri temizlemek ve tüm görüntüleri boyut bakımından standart hale getirmektir. Bu amaçla öncelikle komşu piksellerden belirgin biçimde farklı olan pikselleri temizlemek için her bir görüntü gri seviyeye çevrilmiş ve 3x3'lük komşuluk matrisi kullanılarak ortanca filtre uygulanmıştır. Şekil 3'te orijinal retina görüntüleri ve ortanca filtre uygulandıktan sonra elde edilen retina görüntüleri gösterilmiştir. Ön işlem aşamasından sonra tüm retina görüntüleri 256x256 boyutunda ve gri seviye olarak standart hale getirilmiştir.

B. Sınıflandırma

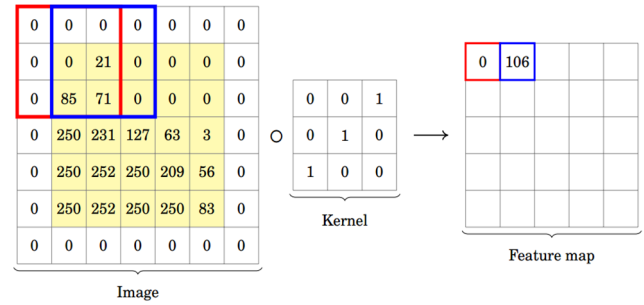
Derin öğrenme algoritmaları arasında yaygın olarak kullanılan CNN (Konvolüsyonel Sinir Ağı) algoritmasıdır. Aslında CNN ileri beslemeli yapay sinir ağının farklı bir modelidir. Bu farklılık öznetelik çıkarma işlemini içine almasından kaynaklanmaktadır [10]. Öznetelik çıkarma ve çoğaltma işlemi konvolüsyonel katmanları ile gerçekleştirilir. Bu katmanda yapılan işlem temelde görüntü işlemede kullanılan normal filtreleme işlemidir. Aslında amaç görüntüye benzer yeni bir görüntü elde etme işlemidir. 7x7'lik bir görüntüye 3x3'lük bir filtre (kernel) kullanarak gerçekleştirilen konvolüsyonel işleminin iki piksel uygulamış hali Şekil 4'te gösterilmiştir. Filtre her adımda bir piksel sağa kaydırılarak devam edilir ve 5x5'lik konvolüsyonel özneteliği elde edilmiş olur. Konvolüsyonel katmanı ile çıkarılıp çoğaltılan öznetelikler Birleştirme (pooling) katmanı ile küçültülür. Maksimum, minimum ve ortanca olmak üzere üç farklı birleştirme yöntemi vardır.

Şekil 5'te birleştirme işlemi gösterilmiştir. 4x4'lük konvolüsyon özneteliğine 2x2'lik bir filtre ile maksimum birleştirme işlemi uygulandığında 2x2'lik görsel elde edilmiştir. Bu işlemden sonra öznetelik çıkarımı işlemi gerçekleştirilmiş ve ayırt edici öznetelikler belirlenmiştir.


Çıkarma (dropout) katmanında sınıflandırma sonucunu etkilemeyen bazı nöronlar etkisiz hale getirilir (Şekil 6). Retina görüntülerini sınıflandırmak için bu çalışmada kullanılan CNN ağı Şekil 7'de ağ tablosu Tablo 1'de gösterilmiştir.




Şekil. 3. (a) Orijinal retina görüntüleri (b) ortanca filtre uygulandıktan sonra elde edilen retina görüntüleri.




Şekil. 4. Konvolüsyon işlemi.



Şekil. 5. Birleştirme işlemi.



Şekil. 6. Çıkarma işlemi.



Şekil. 7. CNN ağ yapısı.

C. Sınıflandırma Sonuçları

Literatürde sınıflandırıcı performansını değerlendirmek için oldukça yaygın olarak kullanılan kıstaslardan biri hata matrisidir. Bu matristen hesaplanan duyarlılık (sensitivity), seçicilik (specificity), doğruluk (accuracy) değerleri ise bir sınıflandırıcının performansı hakkında önemli bilgiler içermektedir. Deneysel çalışmalarda toplam 1000 retina görüntüsü kullanılmıştır. %80 eğitim aşamasında kullanıldığından test aşamasında %20 yani 200 görüntü kullanılmıştır. DP, doğru sınıflandırılmış hastalıklı görüntülerin sayısını, DN, doğru sınıflandırılmış normal görüntülerin sayısını, YP, yanlış sınıflandırılmış hastalıklı görüntülerin sayısını, YN yanlış sınıflandırılmış normal görüntülerin sayısını ifade eder. Deneysel çalışma sonucu elde edilen hata matrisi ve bu matristen hesaplanan duyarlılık, seçicilik ve doğruluk değerleri Tablo 2’de verilmiştir.

TABLO I. CNN AĞINA AİT VERİ TABLOSU

Katman Sayısı	Tip	Öznitelik ve Nöron	Filtre boyutu
0	Girdi	1x256x256	
1	Conv1	32x252x252	5x5
2	Pool1	32x126x126	2x2
3	Conv2	64x124x124	3x3
4	Pool2	64x62x62	2x2
5	Conv3	128x60x60	3x3
6	Pool3	128x30x30	2x2
7	Dropout		
8	Soft-max	2	

TABLO II. ÖNERİLEN YÖNTEME AIT HATA MATRİSİ VE SINIFLANDIRMA ORANLARI

DP	YP	DN	YN	Duyarlılık (%)	Seçicilik (%)	Doğruluk (%)
99	1	98	2	98,02	98,98	98,5

IV. SONUÇ

Bu çalışmada renkli retina görüntülerinden Diyabetik Retinopati hastalığının erken tespiti için son yıllarda oldukça popüler olan derin öğrenmeye dayalı bir yöntem önerilmiştir. Önerilen yöntem %98,5 gibi yüksek bir sınıflandırma başarısına sahiptir. Bu çalışmada görüntü sınıflandırmada oldukça yaygın olarak kullanılan derin öğrenme algoritmalarından CNN yöntemi tercih edilmiştir. CNN algoritmasının diğer algoritmalarla nazaran en büyük avantajı karmaşık problemleri kolay ve hızlı bir şekilde çözebilmeleridir. Bunu yaparken CPU ile beraber GPU kullanılmaktadır. GPU sayesinde oldukça karmaşık problemler çok kısa sürede derin öğrenme yöntemiyle çözülebilmektedir. Derin öğrenme yöntemini diğer yöntemlerden ayıran belirgin özelliklerden biri budur. Diğer bir özellik ise öznitelik kümesi oluşturma işlemini öğrenerek kendi kendine halletmesidir. Bu işlem CNN ağının eğitimi aşamasında gerçekleşmektedir. Geleneksel yöntemlerde öznitelik kümesi kümeyi oluşturan canlıya ve veri setine bağımlı olmakta, sınıflandırma yapmadan önce canlı tarafından manuel olarak hesaplanmaktadır. Buda tamamen otomatik bir sınıflandırma yöntemi olmamaktadır. Bu problemlerin tümü derin öğrenme yöntemi ile aşılmaktadır.

KAYNAKÇA

- [1] Guariguata, L., Whiting, D. R., Hambleton, I., Beagley, J., Linnenkamp, U., and Shaw, J. E., "Global estimates of diabetes prevalence for 2013 and projections for 2035", *Diabetes research and clinical practice*, 103(2), 137-149, 2014
- [2] Sopharak, A., Uyyanonvara, B., and Barman, S., "Simple hybrid method for fine microaneurysm detection from non-dilated diabetic retinopathy retinal images", *Computerized Medical Imaging and Graphics*, 37(5):394-402, 2013.
- [3] Frank, R.N., *Diabetic retinopathy*, 361-388, Michigan, 1995.
- [4] Usman Akram, M., Khalid, S., T F., "Detection and classification diabetic retinopathy", *Computers* 171, 2014.
- [5] Sinthanayothin, C., Boyce, J. F., Williamson, T. H., Cook, H. L., Mensah, E., Lal, S., & Usher, D. (2002). Automated detection of diabetic retinopathy on digital fundus images. *Diabetic medicine*, 19(2), 105-112.
- [6] Quellec, G., Lamard, M., Josselin, P. M., Cazuguel, G., Cochener, B., & Roux, C. (2008). Optimal wavelet transform for the detection of microaneurysms in retina photographs. *IEEE Transactions on Medical Imaging*, 27(9), 1230-1241.
- [7] Osareh, A., Shadgar, B., & Markham, R. (2009). A computational-intelligence-based approach for detection of exudates in diabetic retinopathy images. *IEEE Transactions on Information Technology in Biomedicine*, 13(4), 535-545.
- [8] Chen, X. W., & Lin, X. (2014). Big data deep learning: challenges and perspectives. *IEEE access*, 2, 514-525.
- [9] Graham, B. (2015). Kaggle diabetic retinopathy detection competition report. University of Warwick.
- [10] Ciregan, D., Meier, U., & Schmidhuber, J. (2012, June). Multi-column deep neural networks for image classification. In *Computer vision and pattern recognition (CVPR), 2012 IEEE conference on* (pp. 3642-3649). IEEE.